



École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes
- Rabat

Projet Applied AI

Deep Learning for Diabetic Retinopathy Detection : Ordinal Multilabel Classification from Fundus Images

---

Élève :
Sabbar Soukaina
Braidi Hajar

Encadrant :
Pr. ABNANE Ibtissam
Pr. Ait SkourtBrahim

Année Universitaire 2025-2026

Remerciements

Nous tenons tout d'abord à remercier Allah le Tout-Puissant pour nous avoir accordé la force, la patience et la détermination nécessaires à la réalisation de ce projet.

Nous exprimons notre sincère gratitude à notre encadrante, Professeur Ibtissam Abnane, pour ses conseils éclairés, son expertise et son soutien constant tout au long de ce projet d'apprentissage profond. Ses retours constructifs et son dévouement à l'enseignement ont été déterminants dans l'aboutissement de ce travail et dans notre compréhension des concepts avancés de l'intelligence artificielle appliquée.

Nos remerciements s'adressent également à l'ensemble du corps professoral et de l'équipe académique de l'École Nationale Supérieure d'Informatique et d'Analyse des Systèmes (ENSIAS) pour la qualité de l'environnement pédagogique qu'ils offrent et qui nous a préparés à relever des défis complexes en science des données et en intelligence artificielle.

Nous remercions la communauté open-source et les chercheurs qui ont mis à disposition leurs jeux de données, leurs implémentations et leurs publications. Ce projet n'aurait pas été possible sans la plateforme Kaggle et le dataset APTOS 2019 Blindness Detection.

Enfin, notre profonde reconnaissance va à nos familles pour leur amour inconditionnel, leurs encouragements permanents et leurs sacrifices. Leur confiance en nous a été une source de motivation constante tout au long de nos études.

Résumé

Ce rapport présente un projet d'apprentissage profond axé sur la détection automatisée de la rétinopathie diabétique à partir d'images de fond d'œil, en utilisant une approche novatrice d'encodage ordinal multilabel avec quatre architectures de réseaux de neurones convolutifs (CNN). En exploitant le jeu de données APTOS 2019 Blindness Detection disponible sur Kaggle, nous avons développé et comparé quatre backbones pré-entraînés pour la classification de la sévérité de la rétinopathie diabétique en cinq grades.

Le jeu de données comprend 3 662 images d'entraînement réparties en cinq classes : No DR (1 805 images, 49,3%), Mild (370, 10,1%), Moderate (999, 27,3%), Severe (193, 5,3%) et Proliferative (295, 8,1%), divisées en ensembles d'entraînement (3 112 images, 85%) et de validation (550 images, 15%) par échantillonnage stratifié.

Nous avons implémenté et évalué quatre architectures distinctes avec sortie ordinale multilabel :

— **DenseNet121** : 7,0M paramètres — Accuracy 78,36%, QWK 0,8829
— **EfficientNetB3** : Architecture efficiente — Accuracy 78,91%, QWK 0,8580
— **InceptionV3** : Convolutions multi-échelles — Accuracy 76,73%, QWK 0,8439
— **ResNet50** : Connexions résiduelles — Accuracy 77,45%, QWK 0,8697

Résultats clés : Le modèle DenseNet121 a obtenu les meilleures performances globales avec un Quadratic Weighted Kappa (QWK) de 0,8829, amélioré à 0,8899 après optimisation du seuil de décision (seuil optimal = 0,4062). L'approche d'encodage ordinal multilabel exploite la nature progressive de la maladie en utilisant des sorties sigmoid indépendantes avec binary cross-entropy, permettant au modèle d'apprendre que les classes sont intrinsèquement ordonnées.

Pour gérer le déséquilibre sévère des classes (ratio 9,4 :1 entre la classe majoritaire et minoritaire), nous avons appliqué un pipeline d'augmentation de données agressif incluant des rotations à 360°, des retournements horizontaux et verticaux, ainsi qu'un prétraitement de Ben Graham pour améliorer le contraste des structures rétiniennes. L'optimisation des seuils de décision par la méthode de Nelder-Mead a permis d'améliorer les performances de classification, notamment pour les classes sous-représentées.

Mots-clés : Apprentissage Profond, Rétinopathie Diabétique, Réseaux de Neurones Convolutifs, Encodage Ordinal Multilabel, Classification d'Images Médicales, Transfer Learning, DenseNet121, EfficientNetB3, InceptionV3, ResNet50, Quadratic Weighted Kappa, APTOS 2019.

Abstract

This report presents a deep learning project focused on automated diabetic retinopathy detection from fundus images using a novel ordinal multilabel encoding approach with four convolutional neural network architectures. Using the APTOS 2019 Blindness Detection dataset from Kaggle, we developed and compared four pre-trained backbones for grading diabetic retinopathy severity across five classes.

The dataset comprised 3,662 training images distributed across five classes : No DR (1,805 images, 49.3%), Mild (370, 10.1%), Moderate (999, 27.3%), Severe (193, 5.3%), and Proliferative (295, 8.1%), split into training (3,112 images, 85%) and validation (550 images, 15%) sets using stratified sampling.

We implemented and evaluated four distinct architectures with ordinal multilabel output :

— **DenseNet121** : 7.0M parameters — Accuracy 78.36%, QWK 0.8829
— **EfficientNetB3** : Efficient architecture — Accuracy 78.91%, QWK 0.8580
— **InceptionV3** : Multi-scale convolutions — Accuracy 76.73%, QWK 0.8439
— **ResNet50** : Residual connections — Accuracy 77.45%, QWK 0.8697

The DenseNet121 model achieved the best overall performance with a Quadratic Weighted Kappa (QWK) of 0.8829, improved to 0.8899 after decision threshold optimization (optimal threshold = 0.4062).

Keywords : Deep Learning, Diabetic Retinopathy, Convolutional Neural Networks, Ordinal Multilabel Encoding, Medical Image Classification, Transfer Learning, Quadratic Weighted Kappa, APTOS 2019.

Liste des Abréviations

AI	Artificial Intelligence
AUC	Area Under the Curve
BCE	Binary Cross-Entropy
CNN	Convolutional Neural Network
DL	Deep Learning
DR	Diabetic Retinopathy
EDA	Exploratory Data Analysis
FWHM	Full Width at Half Maximum
GAP	Global Average Pooling
GPU	Graphics Processing Unit
ML	Machine Learning
QWK	Quadratic Weighted Kappa
ReLU	Rectified Linear Unit
RGB	Red Green Blue
ROC	Receiver Operating Characteristic
SGD	Stochastic Gradient Descent
SOTA	State of the Art
TTA	Test-Time Augmentation

Introduction générale

Contexte et Motivation

La rétinopathie diabétique (DR) constitue la principale cause de cécité chez les adultes en âge de travailler dans les pays développés, affectant environ un tiers des 537 millions de personnes diabétiques dans le monde. Cette complication microvasculaire du diabète se caractérise par des lésions progressives de la rétine — microanévrysmes, hémorragies, exsudats et néovascularisation — dont la détection précoce est cruciale pour prévenir la perte irréversible de la vision.

Le diagnostic actuel repose sur l'examen de photographies du fond d'œil par des ophtalmologistes spécialisés, un processus qui présente plusieurs limitations majeures. Premièrement, l'évaluation reste subjective et sujette à une variabilité inter-observateur significative. Deuxièmement, la pénurie mondiale d'ophtalmologistes, particulièrement dans les régions rurales et les pays en développement, limite considérablement l'accès au dépistage. Troisièmement, le volume croissant de patients diabétiques rend le dépistage systématique manuel économiquement insoutenable.

Les avancées récentes en apprentissage profond, notamment les réseaux de neurones convolutifs (CNN), ont révolutionné l'analyse d'images médicales. Ces modèles sont capables d'apprendre automatiquement des représentations hiérarchiques à partir de données brutes, atteignant des performances comparables ou supérieures à celles des experts humains dans diverses tâches de diagnostic par imagerie.

Objectifs du projet

Ce projet explore l'application de quatre architectures CNN pré-entraînées à la classification automatisée de la sévérité de la rétinopathie diabétique à partir d'images de fond d'œil, en utilisant une approche novatrice d'encodage ordinal multilabel. Nos objectifs spécifiques sont :

1. Implémenter un pipeline complet de prétraitement des images rétiniennes incluant le filtrage de Ben Graham et le crop circulaire pour améliorer la qualité du signal.
2. Développer et entraîner quatre architectures CNN distinctes (DenseNet121, EfficientNetB3, InceptionV3, ResNet50) avec une sortie ordinale multilabel à 5 sorties sigmoid.
3. Gérer le déséquilibre sévère des classes (ratio 9,4 :1) par augmentation de données agressive et techniques d'optimisation des seuils.
4. Évaluer et comparer les performances des modèles en utilisant le Quadratic Weighted Kappa (QWK) comme métrique principale, complété par l'accuracy, la précision, le rappel et le F1-score.
5. Démontrer l'efficacité de l'encodage ordinal multilabel qui exploite la nature progressive de la rétinopathie diabétique.
6. Optimiser les seuils de décision post-entraînement par la méthode de Nelder-Mead pour maximiser le QWK.

Aperçu du dataset

Nous utilisons le jeu de données APTOS 2019 Blindness Detection, disponible publiquement sur Kaggle, qui comprend :

- **Total d'images :** 3 662 images d'entraînement + 1 928 images de test
- **Classes :** 5 grades de sévérité (No DR, Mild, Moderate, Severe, Proliferative)
- **Résolution :** Variable, normalisée à 224×224 pixels
- **Split :** Entraînement (3 112 images, 85%) et Validation (550 images, 15%) avec échantillonnage stratifié
- **Déséquilibre :** Ratio 9,4 :1 entre la classe la plus et la moins représentée

Structure du rapport

Ce rapport est organisé comme suit :

- **Chapitre 1 : Introduction et Contexte** présente le domaine médical, la motivation clinique, la formalisation du problème et l'état de l'art en apprentissage profond pour l'imagerie rétinienne.
- **Chapitre 2 : Dataset et Représentation** détaille le jeu de données APTOS 2019, l'analyse exploratoire, le déséquilibre des classes et le protocole de prétraitement.
- **Chapitre 3 : Conception Expérimentale** présente le pipeline d'augmentation, les quatre architectures CNN, l'encodage ordinal multilabel et la stratégie d'entraînement.
- **Chapitre 4 : Résultats et Analyse** rapporte l'évaluation quantitative, les matrices de confusion, l'optimisation des seuils, et l'analyse comparative des modèles.
- Une **Conclusion** synthétise les résultats clés et les perspectives futures.

Table des matières

Remerciements **1**

Résumé **2**

Abstract **3**

Liste des Abréviations **4**

Introduction générale **5**

1 Introduction et Contexte **9**
1.1 Domaine du projet et motivation 9
1.1.1 Contexte clinique 9
1.1.2 Défis diagnostiques actuels 9
1.1.3 Impact attendu de l'IA 10
1.2 Formalisation du problème 10
1.2.1 Définition formelle de la tâche 10
1.3 État de l'art (SOTA) 11
1.3.1 Architectures CNN pour l'imagerie médicale 11
1.3.2 Approches existantes pour la DR 11
1.3.3 Gap identifié 11

2 Dataset et Représentation **12**
2.1 Source et acquisition des données 12
2.1.1 Dataset APTOS 2019 Blindness Detection 12
2.2 Analyse exploratoire des données (EDA) 12
2.2.1 Distribution des classes et déséquilibre 12
2.2.2 Analyse visuelle des images par classe 13
2.2.3 Statistiques du dataset 13
2.3 Prétraitement et protocole de labellisation 14
2.3.1 Origine des labels 14
2.3.2 Prétraitement de Ben Graham 14

3 Conception Expérimentale **15**
3.1 Pipeline de prétraitement et augmentation de données 15
3.1.1 Normalisation 15
3.1.2 Augmentation géométrique et photométrique 15
3.2 Architecture des réseaux de neurones 15
3.2.1 Architecture commune 15

3.2.2 Détail des quatre backbones 16
3.3 Stratégie d'entraînement et optimisation 16
3.3.1 Fonction de perte 16
3.3.2 Configuration d'optimisation 17
3.3.3 Stratégie de split des données 17
3.3.4 Callbacks et monitoring 17
3.3.5 Encodage ordinal multilabel — Détail technique 17
3.3.6 Environnement de développement 18

4 Résultats et Analyse Visuelle **20**
4.1 Évaluation quantitative 20
4.1.1 Tableau comparatif global 20
4.1.2 Observations clés 20
4.2 Interprétation visuelle des modèles 21
4.2.1 Courbes d'entraînement 21
4.2.2 Évolution du QWK pendant l'entraînement 22
4.2.3 Matrices de confusion 22
4.2.4 Rapports de classification détaillés 22
4.2.5 Analyse des erreurs par classe 24
4.3 Comparaison et étude d'ablation 24
4.3.1 Impact de l'optimisation du seuil 24
4.3.2 Test-Time Augmentation (TTA) 24
4.3.3 Ensemble des quatre modèles 26
4.3.4 Classement final et synthèse 28
4.4 Interface Interactive – Gradio 29
4.4.1 Objectif 29
4.4.2 Architecture de l'Interface 29
4.4.3 Visualisation des Prédictions par Grade de Sévérité 29

Conclusion et Perspectives **33**

Chapitre 1

Introduction et Contexte

Ce chapitre établit le contexte médical, technologique et scientifique de l'application de l'apprentissage profond à la détection de la rétinopathie diabétique à partir d'images de fond d'œil, et formule les objectifs spécifiques de notre projet.

1.1 Domaine du projet et motivation

1.1.1 Contexte clinique

La rétinopathie diabétique est une complication microvasculaire du diabète sucré qui affecte la rétine, membrane neurosensorielle tapissant le fond de l'œil. Selon l'Organisation Mondiale de la Santé, elle constitue la première cause de cécité évitable chez les adultes de 20 à 74 ans. La maladie progresse à travers un spectre de sévérité croissante, depuis l'absence de lésions détectables jusqu'à des stades prolifératifs menaçant la vision.

La classification standard de la rétinopathie diabétique comprend cinq grades de sévérité :

- **Grade 0 — No DR :** Absence de rétinopathie diabétique détectable.
- **Grade 1 — Mild (Légère) :** Présence de microanévrysmes uniquement.
- **Grade 2 — Moderate (Modérée) :** Microanévrysmes associés à des hémorragies intrarétiniennes et/ou des exsudats durs.
- **Grade 3 — Severe (Sévère) :** Hémorragies sévères dans les quatre quadrants, veines moniliformes, anomalies microvasculaires intrarétiniennes.
- **Grade 4 — Proliferative (Proliférative) :** Néovascularisation rétinienne et/ou hémorragie vitréenne, stade le plus avancé nécessitant un traitement urgent.

1.1.2 Défis diagnostiques actuels

Le diagnostic de la rétinopathie diabétique repose sur l'examen de photographies du fond d'œil par des ophtalmologistes formés. Ce processus présente des limitations significatives :

1. **Subjectivité diagnostique :** L'évaluation du grade repose sur l'interprétation visuelle du clinicien, entraînant une variabilité inter-observateur notable, particulièrement pour les stades intermédiaires (Mild et Moderate).
2. **Pénurie de spécialistes :** Le déficit mondial en ophtalmologistes, accentué dans les zones rurales et les pays à faible revenu, limite drastiquement l'accès au dépistage.
3. **Volume croissant de patients :** L'augmentation exponentielle du nombre de diabétiques (estimé à 783 millions d'ici 2045) rend le dépistage systématique manuel insoutenable.

4. **Diagnostic tardif :** L'absence de symptômes aux stades précoces conduit fréquemment à un diagnostic tardif, lorsque les lésions rétiniennes sont déjà avancées.

1.1.3 Impact attendu de l'IA

L'automatisation du dépistage par apprentissage profond permettrait de :
— Réduire la variabilité diagnostique en fournissant des évaluations reproductibles.
— Étendre le dépistage aux zones dépourvues de spécialistes via des systèmes de télé-ophtalmologie.
— Accélérer le triage des patients en identifiant rapidement les cas nécessitant une intervention urgente.
— Réduire le coût du dépistage en permettant un pré-screening automatisé avant la consultation spécialisée.

1.2 Formalisation du problème

1.2.1 Définition formelle de la tâche

Le problème est formulé comme une tâche de **classification ordinale multilabel** à partir d'images de fond d'œil. Étant donné une image rétinienne $I \in \mathbb{R}^{H \times W \times 3}$, l'objectif est de prédire le grade de sévérité $y \in \{0, 1, 2, 3, 4\}$.

Approche standard (classification multiclasse) : La classification standard utilise un encodage one-hot avec une sortie softmax :

$$f_\theta(I) \to \hat{y} \in \{0, 1, 2, 3, 4\} \tag{1.1}$$

Notre approche (encodage ordinal multilabel) : Au lieu de prédire une seule classe, le modèle prédit 5 sorties sigmoid indépendantes avec un encodage cumulatif :

Grade	Label One-Hot	Label Ordinal
0 — No DR	$[1, 0, 0, 0, 0]$	$[0, 0, 0, 0, 0]$
1 — Mild	$[0, 1, 0, 0, 0]$	$[1, 0, 0, 0, 0]$
2 — Moderate	$[0, 0, 1, 0, 0]$	$[1, 1, 0, 0, 0]$
3 — Severe	$[0, 0, 0, 1, 0]$	$[1, 1, 1, 0, 0]$
4 — Proliferative	$[0, 0, 0, 0, 1]$	$[1, 1, 1, 1, 1]$

TABLE 1.1 – Comparaison entre l'encodage one-hot standard et l'encodage ordinal multilabel.

L'avantage fondamental de cette approche est que le modèle apprend implicitement que les classes sont ordonnées — la rétinopathie diabétique est une maladie progressive. Le décodage s'effectue par sommation des sorties binarisées :

$$\hat{y} = \sum_{k=1}^{5} \mathbb{1}[\sigma(z_k) > \tau] - 1 \tag{1.2}$$

où σ est la fonction sigmoid, z_k sont les logits de sortie, et τ est le seuil de décision.

1.3 État de l'art (SOTA)

1.3.1 Architectures CNN pour l'imagerie médicale

L'état de l'art en classification d'images rétiniennes s'appuie sur des architectures CNN profondes pré-entraînées sur ImageNet, adaptées au domaine médical par transfer learning :

- **DenseNet :** Introduit des connexions denses (dense connections) où chaque couche reçoit les feature maps de toutes les couches précédentes, favorisant la réutilisation des caractéristiques et réduisant le nombre de paramètres.
- **EfficientNet :** Utilise le compound scaling pour équilibrer simultanément la profondeur, la largeur et la résolution du réseau, atteignant une efficacité paramétrique supérieure.
- **InceptionV3 :** Emploie des modules d'inception avec des convolutions multi-échelles parallèles (1×1, 3×3, 5×5), capturant des motifs à différentes granularités spatiales.
- **ResNet :** Introduit les connexions résiduelles (skip connections) permettant l'entraînement de réseaux très profonds en combattant le problème de la dégradation du gradient : $\mathbf{y} = F(\mathbf{x}) + \mathbf{x}$.

1.3.2 Approches existantes pour la DR

Les travaux récents en détection de rétinopathie diabétique incluent :

- Gulshan et al. (2016) ont démontré des performances de niveau expert avec Inception-v3 (AUC 0,991) pour la classification binaire (referable/non-referable DR).
- La compétition Kaggle EyePACS (2015) a établi des benchmarks importants, avec les meilleures solutions utilisant des ensembles de CNN avec augmentation de données agressive.
- La compétition APTOS 2019 a encouragé l'utilisation d'approches ordinales et de métriques adaptées (QWK) pour évaluer la concordance avec les experts.

1.3.3 Gap identifié

Notre implémentation se distingue par :

- L'utilisation systématique d'un **encodage ordinal multilabel** qui capture la nature progressive de la maladie, contrairement aux approches multiclasses standard.
- La comparaison rigoureuse de **quatre backbones** (DenseNet121, EfficientNetB3, InceptionV3, ResNet50) dans un cadre expérimental unifié.
- L'**optimisation post-entraînement des seuils de décision** par la méthode de Nelder-Mead pour maximiser le QWK.

Chapitre 2

Dataset et Représentation

Ce chapitre décrit le jeu de données APTOS 2019, l'analyse exploratoire des données, le déséquilibre des classes et le protocole de prétraitement implémenté.

2.1 Source et acquisition des données

2.1.1 Dataset APTOS 2019 Blindness Detection

Le jeu de données APTOS 2019 (Asia Pacific Tele-Ophthalmology Society) est un dataset public disponible sur Kaggle, conçu pour la compétition de détection de cécité. Il contient des images de fond d'œil capturées dans des conditions cliniques réelles, présentant une variabilité significative en termes de qualité d'image, éclairage et artéfacts.

- **Images d'entraînement :** 3 662 images labellisées
- **Images de test :** 1 928 images non labellisées
- **Spécifications techniques :** Images RGB de résolution variable, format PNG
- **Espace colorimétrique :** RGB (Red, Green, Blue)
- **Classes :** 5 grades de sévérité (0 à 4)
- **Diversité :** Variabilité en qualité d'image, luminosité, présence d'artéfacts (reflets, poussières sur la lentille), différents types de caméras de fond d'œil

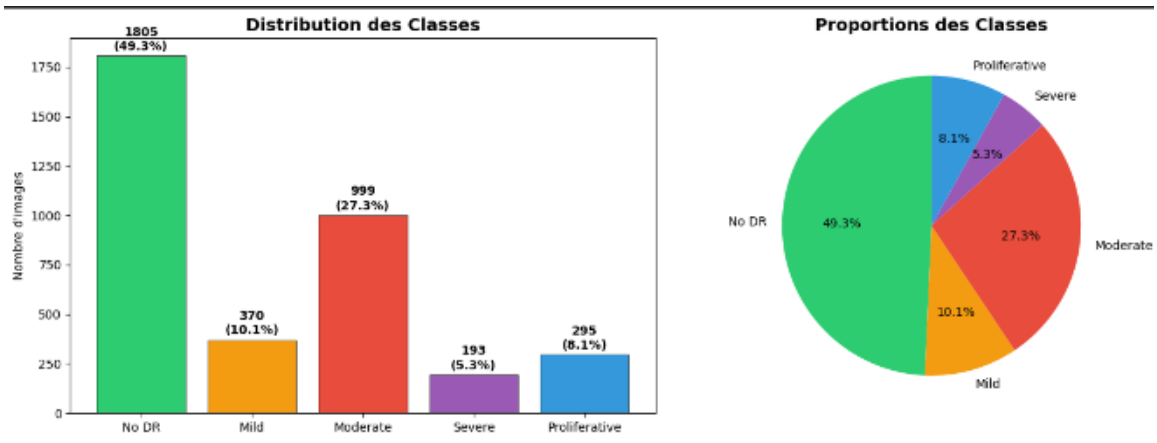


FIGURE 2.1 – Distribution des classes dans le dataset APTOS 2019. La classe No DR représente la majorité (49,3%), tandis que la classe Severe est la plus sous-représentée (5,3%).

2.2 Analyse exploratoire des données (EDA)

2.2.1 Distribution des classes et déséquilibre

L'analyse de la distribution des classes révèle un déséquilibre significatif :

Classe	Grade	Nombre d'images	Pourcentage
No DR	0	1 805	49,3%
Mild	1	370	10,1%
Moderate	2	999	27,3%
Severe	3	193	5,3%
Proliferative	4	295	8,1%
Total		**3 662**	**100%**

TABLE 2.1 – Composition du dataset APTOS 2019 par classe.

Le ratio de déséquilibre entre la classe la plus représentée (No DR, 1 805 images) et la classe la moins représentée (Severe, 193 images) est de **9,4 :1**. Ce déséquilibre sévère nécessite des stratégies spécifiques : augmentation de données agressive, encodage ordinal multilabel, et optimisation des seuils de décision.

2.2.2 Analyse visuelle des images par classe



FIGURE 2.2 – Exemples d'images du fond d'œil pour chaque grade de rétinopathie diabétique. On observe la progression des lésions rétiniennes, des microanévrysmes isolés (Mild) à la néovascularisation diffuse (Proliferative).

L'examen visuel des images révèle :
— Une variabilité importante de qualité d'image (luminosité, contraste, netteté).
— La présence d'artéfacts (reflets, poussières sur la lentille, bords noirs variables).
— Des différences subtiles entre grades adjacents (Mild/Moderate), rendant la classification fine particulièrement difficile.
— Des lésions caractéristiques de plus en plus prononcées aux stades avancés.

2.2.3 Statistiques du dataset

— **Total d'images :** 3 662
— **Nombre de classes :** 5
— **Classe la plus large :** No DR (1 805 images)
— **Classe la plus petite :** Severe (193 images)
— **Ratio de déséquilibre :** 9,4×

2.3 Prétraitement et protocole de labellisation

2.3.1 Origine des labels

Les labels du dataset APTOS 2019 ont été attribués par des ophtalmologistes certifiés lors de campagnes de dépistage en Inde. Chaque image a été évaluée et classée selon l'échelle internationale de sévérité de la rétinopathie diabétique (grades 0 à 4). Les labels sont fournis dans un fichier CSV associant chaque identifiant d'image à son grade diagnostique.

2.3.2 Prétraitement de Ben Graham

LLe prétraitement de Ben Graham est une technique de traitement d'image spécifiquement conçue pour les images rétiniennes. Son rôle principal est d'améliorer la qualité visuelle des photographies de fond d'œil en rehaussant les détails locaux et en réduisant les artefacts d'illumination inhérents aux caméras ophtalmiques. En pratique, ce filtre permet de rendre plus visibles les structures anatomiques et pathologiques de la rétine — telles que les vaisseaux sanguins, les microanévrysmes et les exsudats — qui sont déterminantes pour la classification de la sévérité de la rétinopathie diabétique. Il constitue ainsi une étape de prétraitement essentielle avant toute extraction de caractéristiques par un réseau de neurones convolutif.. Elle consiste à :

1. **Crop des bords noirs :** Suppression automatique des régions non-informatives (fond noir) entourant l'image rétinienne, basée sur un seuil d'intensité.
2. **Redimensionnement :** Mise à l'échelle uniforme à 224×224 pixels.
3. **Enhancement du contraste local :** Application d'une opération de soustraction de flou gaussien :

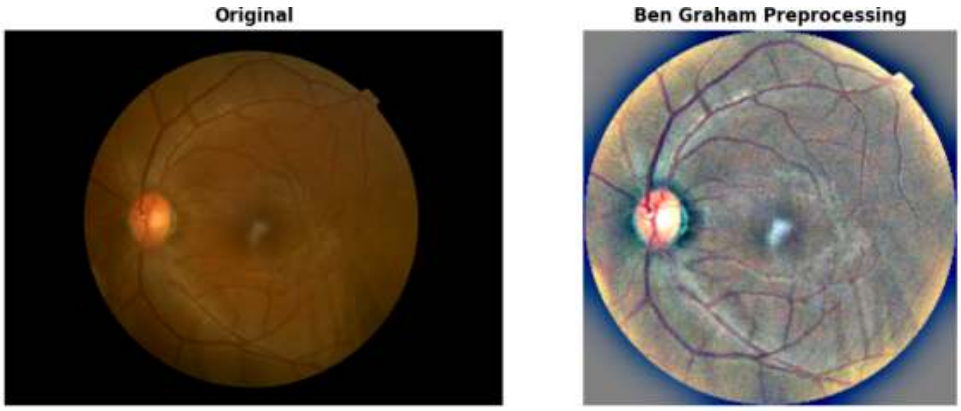


FIGURE 2.3 – Effet du prétraitement de Ben Graham sur une image rétinienne. Le filtrage améliore considérablement la visibilité des structures vasculaires et des lésions.

Chapitre 3

Conception Expérimentale

3.1 Pipeline de prétraitement et augmentation de données

3.1.1 Normalisation

Les images prétraitées par le filtre de Ben Graham sont normalisées dans l'intervalle $[0, 1]$ par division par 255 :

$$I_{\text{norm}} = \frac{I_{\text{processed}}}{255.0} \tag{3.1}$$

Aucune normalisation aux statistiques d'ImageNet (mean/std) n'a été appliquée, le prétraitement de Ben Graham transformant significativement la distribution des intensités par rapport aux images naturelles.

3.1.2 Augmentation géométrique et photométrique

L'augmentation de données est critique compte tenu du déséquilibre des classes (9,4×) et de la taille limitée du dataset. Le pipeline d'augmentation exploite les invariances spécifiques au domaine rétinien :

- **Rotation à 360° :** Les images rétiniennes ne possèdent pas d'orientation préférentielle, justifiant une rotation complète.
- **Retournement horizontal et vertical :** L'œil gauche est le miroir de l'œil droit, rendant les flips cliniquement valides.
- **Zoom ±15% :** Simule des variations de distance focale et de champ de vue entre caméras.
- **Translation ±10% :** Compense le centrage imparfait du disque optique dans l'image.
- **Remplissage constant (noir) :** Les pixels hors-champ sont remplis avec la valeur 0 (noir), cohérent avec le fond des images rétiniennes.

L'augmentation est appliquée uniquement pendant l'entraînement via un `ImageDataGenerator` de Keras, avec un batch size de 32 et un seed fixe (42) pour la reproductibilité.

3.2 Architecture des réseaux de neurones

3.2.1 Architecture commune

Tous les modèles partagent la même architecture de sortie, seul le backbone diffère :

$$\text{Backbone (ImageNet)} \rightarrow \text{GlobalAveragePooling2D} \rightarrow \text{Dropout}(0.5) \rightarrow \text{Dense}(5, \text{sigmoid}) \tag{3.2}$$

— **Backbone :** Réseau pré-entraîné sur ImageNet (`include_top=False`) servant d'extracteur de caractéristiques.
— **Global Average Pooling (GAP) :** Réduit les feature maps spatiales en un vecteur de caractéristiques en calculant la moyenne sur les dimensions spatiales, éliminant les couches fully-connected massives.
— **Dropout (50%) :** Régularisation par désactivation aléatoire de 50% des neurones pendant l'entraînement, réduisant le surajustement.
— **Dense(5, sigmoid) :** Couche de sortie avec 5 neurones et activation sigmoid, chaque sortie modélisant un problème binaire indépendant dans le cadre de l'encodage ordinal.

3.2.2 Détail des quatre backbones

Modèle	Params totaux	Params entraînables	Caractéristique clé
DenseNet121	7 042 629	6 958 981	Dense connections
EfficientNetB3	∼12M	∼11M	Compound scaling
InceptionV3	∼23M	∼22M	Multi-scale inception modules
ResNet50	∼25M	∼24M	Residual skip connections

TABLE 3.1 – Résumé des quatre architectures backbones utilisées.

DenseNet121 se distingue par son architecture à connexions denses où chaque couche reçoit en entrée les feature maps de toutes les couches précédentes. Cette conception favorise la réutilisation des caractéristiques, améliore le flux du gradient et réduit le nombre de paramètres nécessaires (7M vs 25M pour ResNet50).

EfficientNetB3 utilise le Neural Architecture Search (NAS) et le compound scaling pour optimiser simultanément la profondeur, la largeur et la résolution du réseau, offrant un excellent rapport performance/paramètres.

InceptionV3 emploie des modules d'inception avec des convolutions factoriées parallèles ($1\times1, 3\times3, 5\times5$) capturant des motifs à différentes échelles spatiales, particulièrement adapté aux lésions rétiniennes de tailles variables.

ResNet50 utilise des connexions résiduelles (skip connections) permettant l'entraînement stable de réseaux profonds en combattant la dégradation du gradient : $\mathbf{y} = F(\mathbf{x}) + \mathbf{x}$.

3.3 Stratégie d'entraînement et optimisation

3.3.1 Fonction de perte

La loss utilisée est la **binary cross-entropy** (BCE), chaque sortie sigmoid étant traitée comme un problème de classification binaire indépendant :

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N \cdot K} \sum_{i=1}^{N} \sum_{k=1}^{K} [y_{ik} \log(\hat{y}_{ik}) + (1 - y_{ik}) \log(1 - \hat{y}_{ik})] \tag{3.3}$$

où N est le nombre d'échantillons, $K = 5$ est le nombre de sorties, y_{ik} est le label ordinal et $\hat{y}_{ik}$ est la probabilité sigmoid prédite.

3.3.2 Configuration d'optimisation

Hyperparamètre	Valeur
Taille des images	224×224×3
Batch size	32
Learning rate	5×10^{-5}
Optimiseur	Adam
Max epochs	30
Early stopping	patience = 10 (monitor : val_loss)
LR scheduler	ReduceLROnPlateau (factor=0.5, patience=4, min_lr=10^{-7})
Fonction de perte	Binary Cross-Entropy
Validation split	15% stratifié
Seed	42

TABLE 3.2 – Hyperparamètres d'entraînement communs à tous les modèles.

3.3.3 Stratégie de split des données

Les données ont été divisées en ensembles d'entraînement et de validation par échantillonnage stratifié (`train_test_split` avec `stratify`), maintenant les proportions des classes dans chaque split :

Split	Nombre d'images	Pourcentage
Entraînement	3 112	85%
Validation	550	15%

TABLE 3.3 – Split entraînement/validation stratifié.

3.3.4 Callbacks et monitoring

- **KappaMetrics (callback personnalisé) :** Calcule le Quadratic Weighted Kappa à chaque epoch sur l'ensemble de validation et sauvegarde les poids du meilleur modèle selon cette métrique.
- **EarlyStopping :** Arrête l'entraînement si la val_loss ne s'améliore pas pendant 10 epochs consécutives, avec restauration des meilleurs poids.
- **ReduceLROnPlateau :** Réduit le learning rate d'un facteur 0,5 si la val_loss stagne pendant 4 epochs, avec un minimum de 10^{-7}.

3.3.5 Encodage ordinal multilabel — Détail technique

L'idée fondamentale de l'encodage ordinal multilabel est de transformer le problème de classification multiclasse en une série de **5 problèmes binaires cumulatifs**, exploitant ainsi la nature progressive et ordonnée de la rétinopathie diabétique. Plutôt que de prédire directement un grade parmi $\{0, 1, 2, 3, 4\}$, le modèle apprend à répondre à 5 questions binaires successives : *"La sévérité est-elle au moins de grade k ?"*

La conversion des labels en encodage ordinal s'effectue par accumulation :

$$y_{\text{ordinal}}[i,k] = \begin{cases} 1 & \text{si grade}(i) \geq k \\ 0 & \text{sinon} \end{cases} \quad \text{pour } k \in \{1,2,3,4,5\} \tag{3.4}$$

Comme illustré dans la figure 3.1, chaque classe produit un vecteur binaire cumulatif distinct :

```
Classe 0 (No DR          ) -> [ True False False False False]
Classe 1 (Mild           ) -> [ True  True False False False]
Classe 2 (Moderate       ) -> [ True  True  True False False]
Classe 3 (Severe         ) -> [ True  True  True  True False]
Classe 4 (Proliferative  ) -> [ True  True  True  True  True]
```

FIGURE 3.1 – Représentation de l'encodage ordinal multilabel pour chaque grade de sévérité de la rétinopathie diabétique. Chaque ligne correspond à un grade, et chaque position du vecteur binaire indique si le seuil cumulatif correspondant est franchi.

Cette représentation illustre clairement la logique cumulative de l'encodage : un patient atteint de rétinopathie **Moderate** (Grade 2) a nécessairement franchi les seuils des grades inférieurs (Mild, puis Moderate), ce qui se traduit par les deux premières positions à `True`. De même, un patient au stade **Proliferative** (Grade 4), stade le plus sévère, active toutes les sorties à `True`, reflétant le fait qu'il a progressé à travers tous les stades précédents. À l'inverse, un patient **No DR** (Grade 0) n'ayant franchi aucun seuil de sévérité, toutes ses sorties sont à `False`.

Le décodage inverse, permettant de retrouver le grade prédit à partir des sorties sigmoid, est réalisé par sommation des sorties binarisées :

$$\hat{y}_i = \text{clip}\left(\sum_{k=1}^{5} \mathbb{1}[\hat{p}_{ik} > \tau] - 1,\ 0,\ 4\right) \tag{3.5}$$

où τ est le seuil de décision optimisé par la méthode de Nelder-Mead. Concrètement, le grade prédit correspond au **nombre de sorties sigmoid dépassant le seuil** τ, diminué de 1. Par exemple, si le modèle produit le vecteur binarisé $[1,1,1,0,0]$, le grade prédit sera $3-1=2$ (Moderate).

Les distributions résultantes de l'encodage ordinal montrent une accumulation progressive des positifs par rapport à l'encodage one-hot original :

— **Encodage one-hot :** [1805, 370, 999, 193, 295]
— **Encodage ordinal :** [3662, 1857, 1487, 488, 295]

Cette redistribution est particulièrement bénéfique pour la gestion du déséquilibre des classes : les sorties correspondant aux grades élevés (Severe, Proliferative) accumulent davantage d'exemples positifs qu'en encodage one-hot, facilitant ainsi l'apprentissage des stades avancés de la maladie.

3.3.6 Environnement de développement

— **Plateforme :** Kaggle Notebooks (cloud-based)
— **GPU :** 2× Tesla T4 (16 GB VRAM chacun)
— **Framework :** TensorFlow 2.19.0 / Keras

— **Python :** 3.12
— **Bibliothèques clés :** NumPy, OpenCV, Pandas, Scikit-learn, Matplotlib, Seaborn, SciPy

Chapitre 4

Résultats et Analyse Visuelle

Ce chapitre présente l'évaluation quantitative complète, les matrices de confusion, l'optimisation des seuils de décision et l'analyse comparative des quatre architectures.

4.1 Évaluation quantitative

4.1.1 Tableau comparatif global

Modèle	Accuracy	QWK	QWK Optimisé	Seuil optimal
DenseNet121	78,36%	0,8829	**0,8899**	0,4062
EfficientNetB3	78,91%	0,8580	0,8580	0,5000
InceptionV3	76,73%	0,8439	0,8465	0,5469
ResNet50	77,45%	0,8697	0,8697	0,5000

TABLE 4.1 – Comparaison complète des performances sur l'ensemble de validation (550 images). Le meilleur modèle est DenseNet121 avec un QWK optimisé de 0,8899.

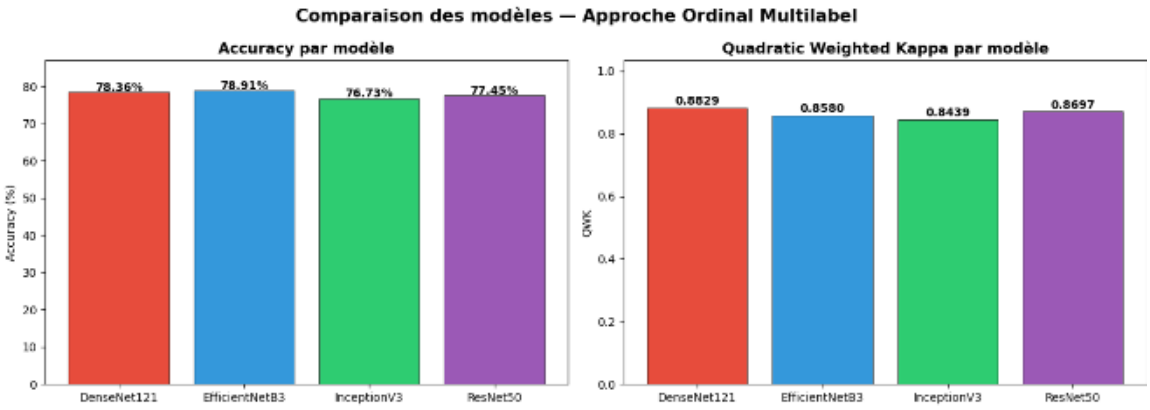


FIGURE 4.1 – Comparaison visuelle des performances des quatre modèles sur l'ensemble de validation.

4.1.2 Observations clés

DenseNet121 — Meilleur modèle global : Le modèle DenseNet121 a obtenu le meilleur Quadratic Weighted Kappa (0,8829), métrique principale de la compétition APTOS. Après optimisation du seuil de décision à 0,4062 (au lieu du seuil standard de 0,5), le QWK s'améliore à 0,8899, soit un gain de +0,0069. La réduction du seuil indique que le modèle bénéficie d'une sensibilité accrue pour les classes de sévérité élevée.

EfficientNetB3 — Meilleure accuracy brute : Avec 78,91% d'accuracy, EfficientNetB3 surpasse légèrement DenseNet121 en accuracy brute, mais présente un QWK inférieur (0,8580). L'optimisation du seuil n'améliore pas ses performances (seuil optimal = 0,5), suggérant que le seuil par défaut est déjà optimal pour cette architecture.

ResNet50 — Forte performance : ResNet50 obtient un QWK de 0,8697, se positionnant en deuxième place, démontrant l'efficacité des connexions résiduelles pour cette tâche.

InceptionV3 — Performance la plus faible : Avec 76,73% d'accuracy et 0,8439 de QWK, InceptionV3 est le modèle le moins performant, potentiellement dû à sa complexité paramétrique supérieure augmentant le risque de surajustement sur ce dataset de taille modeste.

4.2 Interprétation visuelle des modèles

4.2.1 Courbes d'entraînement

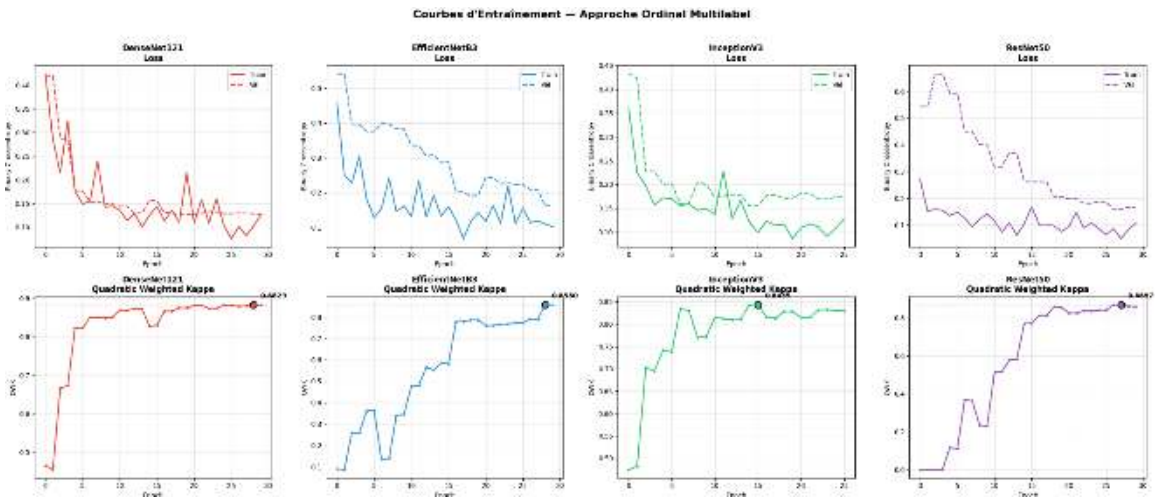
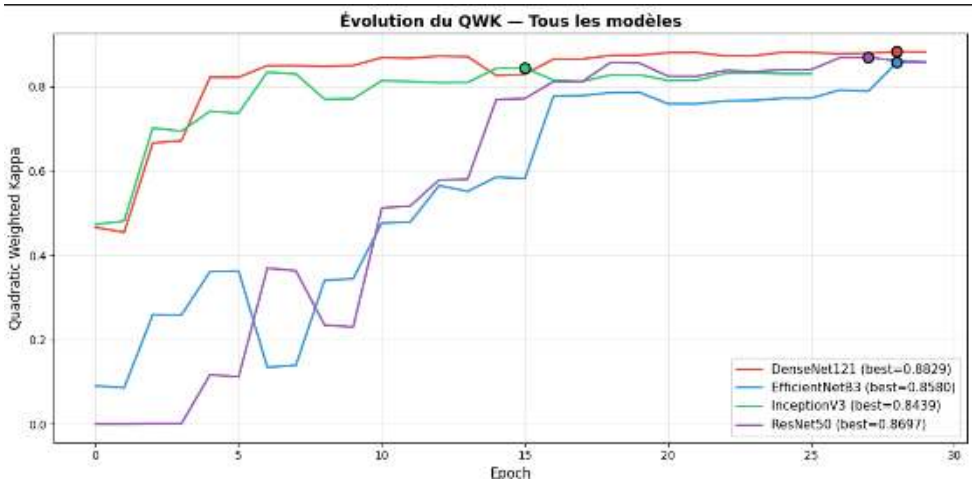


FIGURE 4.2 – Courbes d'entraînement (loss et accuracy) pour les quatre architectures CNN sur 30 epochs maximum.

4.2.2 Évolution du QWK pendant l'entraînement



4.2.3 Matrices de confusion

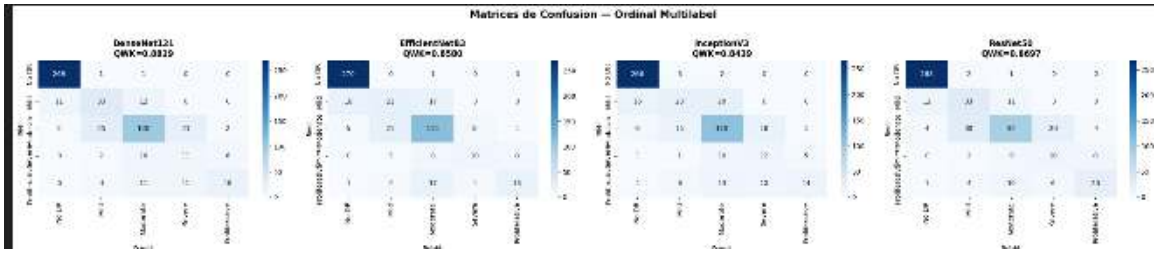


FIGURE 4.3 – Matrices de confusion des quatre architectures sur les 550 images de validation.

4.2.4 Rapports de classification détaillés

DenseNet121 (Meilleur modèle) :

Classe	Precision	Recall	F1-Score	Support
No DR	0,9539	0,9926	0,9729	271
Mild	0,5077	0,5893	0,5455	56
Moderate	0,7463	0,6667	0,7042	150
Severe	0,2558	0,3793	0,3056	29
Proliferative	0,6923	0,4091	0,5143	44
Accuracy			**0,7836**	550
Macro avg	0,6312	0,6074	0,6085	550
Weighted avg	0,7941	0,7836	0,7842	550

TABLE 4.2 – Rapport de classification détaillé pour DenseNet121 sur l'ensemble de validation.

EfficientNetB3 :

Classe	Precision	Recall	F1-Score	Support
No DR	0,9184	0,9963	0,9558	271
Mild	0,4286	0,3750	0,4000	56
Moderate	0,7278	0,7667	0,7468	150
Severe	0,4545	0,3448	0,3922	29
Proliferative	0,6667	0,4091	0,5070	44
Accuracy			**0,7891**	550
Macro avg	0,6392	0,5784	0,6003	550
Weighted avg	0,7719	0,7891	0,7766	550

TABLE 4.3 – Rapport de classification détaillé pour EfficientNetB3 sur l'ensemble de validation.

InceptionV3 :

Classe	Precision	Recall	F1-Score	Support
No DR	0,9172	0,9815	0,9483	271
Mild	0,4444	0,3571	0,3960	56
Moderate	0,7097	0,7333	0,7213	150
Severe	0,3000	0,4138	0,3478	29
Proliferative	0,7000	0,3182	0,4375	44
Accuracy			**0,7673**	550
Macro avg	0,6143	0,5608	0,5702	550
Weighted avg	0,7626	0,7673	0,7576	550

TABLE 4.4 – Rapport de classification détaillé pour InceptionV3 sur l'ensemble de validation.

ResNet50 :

Classe	Precision	Recall	F1-Score	Support
No DR	0,9404	0,9889	0,9640	271
Mild	0,4648	0,5893	0,5197	56
Moderate	0,7480	0,6133	0,6740	150
Severe	0,2778	0,3448	0,3077	29
Proliferative	0,6571	0,5227	0,5823	44
Accuracy			**0,7745**	550
Macro avg	0,6176	0,6118	0,6095	550
Weighted avg	0,7819	0,7745	0,7745	550

TABLE 4.5 – Rapport de classification détaillé pour ResNet50 sur l'ensemble de validation.

4.2.5 Analyse des erreurs par classe

L'analyse des rapports de classification révèle des patterns cohérents à travers les quatre modèles :

- **No DR (Grade 0) :** Excellentes performances pour tous les modèles (Recall $> 0{,}98$, F1 $> 0{,}95$). La classe majoritaire est bien apprise grâce à l'abondance d'exemples.
- **Mild (Grade 1) :** Performances faibles (F1 : 0,40–0,55). Cette classe est la plus difficile car les microanévrysmes sont subtils et facilement confondus avec les images saines ou modérées.
- **Moderate (Grade 2) :** Performances intermédiaires (F1 : 0,67–0,75). La deuxième classe la plus représentée bénéficie d'un nombre suffisant d'exemples.
- **Severe (Grade 3) :** Performances les plus faibles (F1 : 0,31–0,39). La classe la moins représentée (193 images) est systématiquement confondue avec Moderate et Proliferative.
- **Proliferative (Grade 4) :** Performances variables (F1 : 0,44–0,58). Le recall reste faible, indiquant que de nombreux cas prolifératifs sont sous-diagnostiqués.

4.3 Comparaison et étude d'ablation

4.3.1 Impact de l'optimisation du seuil

Modèle	Seuil	QWK avant	QWK après	Gain
DenseNet121	0,4062	0,8829	0,8899	+0,0069
EfficientNetB3	0,5000	0,8580	0,8580	+0,0000
InceptionV3	0,5469	0,8439	0,8465	+0,0026
ResNet50	0,5000	0,8697	0,8697	+0,0000

TABLE 4.6 – Impact de l'optimisation du seuil de décision par Nelder-Mead sur le QWK.

L'optimisation des seuils montre que :

- DenseNet121 bénéficie d'un seuil réduit (0,4062), augmentant sa sensibilité aux classes de sévérité élevée et améliorant le QWK de +0,0069.
- InceptionV3 bénéficie légèrement d'un seuil supérieur (0,5469), réduisant les faux positifs.
- EfficientNetB3 et ResNet50 sont optimaux au seuil par défaut de 0,5.

4.3.2 Test-Time Augmentation (TTA)

Principe

Le Test-Time Augmentation (TTA) est une technique d'inférence qui consiste à prédire sur N_{aug} versions augmentées de chaque image au moment du test, puis à moyenner les probabilités sigmoid résultantes. Contrairement à l'augmentation d'entraînement qui

génère de la diversité pour régulariser le modèle, le TTA exploite les invariances géométriques du domaine rétinien pour réduire la variance des prédictions et améliorer la robustesse face aux variations d'acquisition.

Augmentations appliquées

Les 8 transformations appliquées exploitent les invariances spécifiques aux images rétiniennes : l'absence d'orientation préférentielle (rotations) et la symétrie œil gauche/droit (flips).

TABLE 4.7 – Les 8 augmentations du TTA exploitées lors de l'inférence.

N°	Augmentation	Justification clinique
1	Image originale	Référence (toujours incluse)
2	Flip horizontal	Symétrie œil gauche/droit
3	Flip vertical	Invariance verticale
4	Flip H+V combiné	Rotation équivalente à 180°
5	Rotation 90°	Pas d'orientation préférentielle
6	Rotation 180°	Idem
7	Rotation 270°	Idem
8	Zoom central (crop 90% + resize)	Variation du champ de vue

Résultats du TTA

Le TTA est appliqué sur les 550 images de validation pour chacun des quatre modèles. Le seuil de décision est ensuite re-optimisé par Nelder-Mead sur les probabilités moyennées pour maximiser le QWK.

TABLE 4.8 – Impact du TTA sur le Quadratic Weighted Kappa (QWK) pour chaque modèle. La colonne *TTA+Opt* correspond au TTA avec seuil re-optimisé.

Modèle	Sans TTA	TTA (seuil 0.5)	TTA+Opt	Gain
DenseNet121	0,8801	0,8887	**0,8912**	+0,0111
EfficientNetB3	0,8397	0,8401	0,8756	+0,0359
InceptionV3	0,8588	0,8591	0,8591	+0,0003
ResNet50	0,8636	0,8741	0,8742	+0,0106

Analyse de l'impact du TTA

L'analyse des résultats révèle des comportements distincts selon les architectures :

— **DenseNet121** bénéficie d'un gain significatif de +0,0111 QWK, confirmant sa position de meilleur modèle individuel avec un QWK de 0,8912 après TTA et optimisation du seuil (seuil optimal = 0,4875).

— **EfficientNetB3** obtient le gain le plus important (+0,0359), suggérant que ses prédictions brutes présentaient une variance élevée que le moyennage du TTA corrige efficacement. Le seuil optimal très bas (0,3000) indique une tendance du modèle à sous-estimer les probabilités sigmoid.

— **ResNet50** montre un gain modéré (+0,0106) avec un seuil optimal de 0,4875, cohérent avec la stabilité des connexions résiduelles.
— **InceptionV3** ne bénéficie quasiment pas du TTA (+0,0003), indiquant des prédictions déjà stables mais potentiellement déjà biaisées, que le moyennage ne corrige pas.

4.3.3 Ensemble des quatre modèles

Principe

L'approche d'ensemble vise à exploiter la complémentarité des quatre architectures en combinant leurs prédictions TTA. Chaque backbone capte des caractéristiques différentes des images rétiniennes : DenseNet121 favorise la réutilisation des features, EfficientNetB3 optimise l'équilibre profondeur/largeur, InceptionV3 capture des motifs multi-échelles, et ResNet50 assure un flux de gradient stable. Trois stratégies de combinaison sont évaluées :

1. **Moyenne simple :** Poids égaux ($w_i = 0{,}25$) pour les 4 modèles.
2. **Moyenne pondérée par QWK :** Poids proportionnels aux performances QWK individuelles après TTA.
3. **Ensemble optimisé :** Poids et seuil de décision optimisés conjointement par la méthode de Nelder-Mead.

Optimisation des poids d'ensemble

La prédiction de l'ensemble est définie par :

$$\hat{p}_{\text{ens}}(x) = \sum_{m=1}^{4} w_m \cdot \hat{p}_m^{\text{TTA}}(x) \tag{4.1}$$

Les poids optimaux $\mathbf{w}^*$ et le seuil optimal τ^* sont obtenus par :

$$(\mathbf{w}^*, \tau^*) = \arg\min_{\mathbf{w},\tau} \left(1 - \text{QWK}\left(\mathbf{y},\ \hat{\mathbf{y}}(\hat{p}_{\text{ens}},\ \tau)\right)\right) \quad \text{s.c.} \quad \sum_{m=1}^{4} w_m = 1,\ w_m \geq 0 \tag{4.2}$$

Résultats de l'ensemble

TABLE 4.9 – Poids optimaux de l'ensemble pour chaque stratégie de combinaison.

Stratégie	**DenseNet121**	**EfficientNetB3**	**InceptionV3**	**ResNet50**
Moyenne simple	0,2500	0,2500	0,2500	0,2500
Pondérée par QWK	0,2546	0,2502	0,2455	0,2498
Optimisée	0,2468	0,2524	0,2297	**0,2711**

TABLE 4.10 – Comparaison complète : Individuel vs TTA vs Ensemble sur l'ensemble de validation (550 images). Le gain est calculé par rapport au meilleur modèle individuel sans TTA (DenseNet121, QWK = 0,8801).

Méthode	**Accuracy**	**QWK**	**Gain**
Meilleur individuel (DenseNet121)	77,82%	0,8801	—
+ Seuil optimisé	77,82%	0,8819	+0,0018
+ TTA ×8 + seuil optimisé	77,82%	0,8912	+0,0111
Ensemble simple (4 modèles)	79,45%	0,8747	−0,0054
Ensemble pondéré (par QWK)	79,64%	0,8752	−0,0049
★ **Ensemble optimisé (poids+seuil)**	**78,55%**	**0,8964**	**+0,0163**

Analyse des résultats de l'ensemble

Plusieurs observations émergent de l'analyse des résultats :

La **moyenne simple** et la **moyenne pondérée** obtiennent un QWK inférieur au meilleur modèle individuel avec TTA (0,8747 et 0,8752 vs 0,8912), car le seuil par défaut de 0,5 n'est pas adapté aux probabilités moyennées de l'ensemble. Cependant, leur accuracy brute est supérieure (79,45% et 79,64%), indiquant une meilleure calibration globale.

L'**ensemble optimisé**, avec des poids et un seuil ajustés conjointement (seuil optimal = 0,3390), atteint le **meilleur QWK global de 0,8964**, soit un gain de +0,0163 par rapport à la baseline. Ce seuil réduit augmente la sensibilité aux classes de sévérité élevée, cohérent avec l'objectif clinique de minimiser les faux négatifs pour les stades avancés.

Les poids optimisés attribuent une légère prépondérance à **ResNet50** (0,2711) et réduisent le poids d'**InceptionV3** (0,2297), reflétant la contribution relative de chaque architecture à la performance de l'ensemble.

Rapport de classification de l'ensemble optimisé

TABLE 4.11 – Rapport de classification détaillé pour l'ensemble optimisé (4 modèles + TTA, seuil = 0,3390) sur l'ensemble de validation.

Classe	**Precision**	**Recall**	**F1-Score**	**Support**
No DR	0,9603	0,9815	0,9708	271
Mild	0,5946	0,3929	0,4731	56
Moderate	0,7413	0,7067	0,7235	150
Severe	0,2449	0,4138	0,3077	29
Proliferative	0,5909	0,5909	**0,5909**	44
Accuracy			**0,7855**	550
Macro avg	0,6264	0,6172	0,6132	550
Weighted avg	0,7960	0,7855	0,7873	550

L'ensemble optimisé améliore notablement les performances sur la classe **Proliferative** (recall 0,5909 vs 0,4091 pour DenseNet121 seul, F1-score 0,5909 vs 0,5143), confirmant que la complémentarité des architectures bénéficie particulièrement aux classes sous-

représentées. La classe **Severe** reste la plus difficile avec un F1-score de 0,3077, limitée par sa faible représentation (29 images de validation).

Visualisation comparative

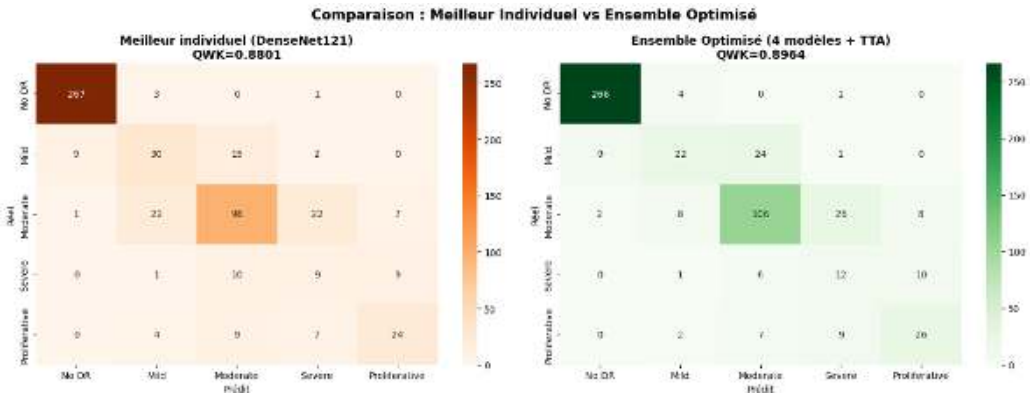


FIGURE 4.4 – Comparaison des matrices de confusion : meilleur modèle individuel vs ensemble optimisé.

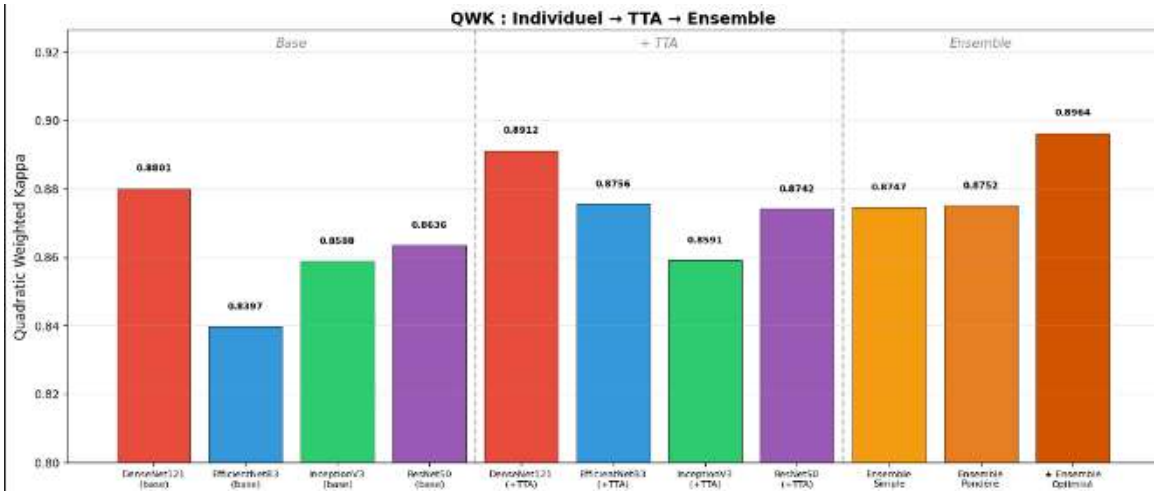


FIGURE 4.5 – Progression du QWK : Base → TTA → Ensemble.

4.3.4 Classement final et synthèse

En intégrant l'ensemble des techniques d'amélioration post-entraînement (optimisation des seuils, TTA, ensemble), le classement final des approches évaluées est :

1. **Ensemble optimisé (4 modèles + TTA) :** QWK = **0,8964**, meilleure performance globale. L'optimisation conjointe des poids et du seuil (0,3390) exploite la complémentarité des quatre architectures.
2. **DenseNet121 + TTA :** QWK = 0,8912, meilleur modèle individuel. Avec seulement 7M de paramètres, il surpasse des architectures plus complexes, démontrant l'efficacité des connexions denses pour l'imagerie rétinienne.

3. **EfficientNetB3 + TTA :** QWK = 0,8756, gain le plus important grâce au TTA (+0,0359), suggérant une variance initiale élevée corrigée par le moyennage.
4. **ResNet50 + TTA :** QWK = 0,8742, performance stable grâce aux connexions résiduelles.
5. **InceptionV3 + TTA :** QWK = 0,8591, performances les plus faibles. La complexité des modules d'inception semble entraîner un surajustement sur ce dataset de taille limitée.

Le gain total entre la baseline (DenseNet121, QWK = 0,8801) et l'ensemble optimisé (QWK = 0,8964) est de **+0,0163 QWK**, démontrant l'intérêt cumulatif du TTA et de l'approche d'ensemble pour cette tâche de classification ordinale.

4.4 Interface Interactive – Gradio

4.4.1 Objectif

Pour démontrer l'applicabilité clinique du système, nous avons développé une **interface web interactive** utilisant la bibliothèque Gradio. Cette interface permet à un utilisateur (clinicien ou chercheur) d'uploader une image rétinienne et d'obtenir instantanément le grade de rétinopathie diabétique prédit par le meilleur modèle.

4.4.2 Architecture de l'Interface

L'interface Gradio comprend trois onglets :

— **Onglet 1 – Prédiction :** Upload d'une image rétinienne → prétraitement Ben Graham → prédiction du grade DR avec détails des sorties sigmoid.

— **Onglet 2 – Test par classe :** Sélection d'une classe pour charger une image aléatoire du dataset et vérifier la prédiction (correct / erreur).

— **Onglet 3 – Dashboard :** Visualisation interactive des résultats (comparaison, matrices de confusion, courbes QWK, tableau récapitulatif).

Le modèle utilisé est DenseNet121 avec le seuil optimisé (0.4062), atteignant un QWK de 0.8899.

4.4.3 Visualisation des Prédictions par Grade de Sévérité

Les figures suivantes illustrent le fonctionnement de l'interface pour chaque grade de rétinopathie diabétique. Pour chaque cas, l'interface affiche l'image originale, l'image prétraitée par Ben Graham, le grade prédit avec l'icône de sévérité, et les détails des 5 sorties sigmoid.

Cas 1 : Grade 0 – No DR (Pas de rétinopathie)

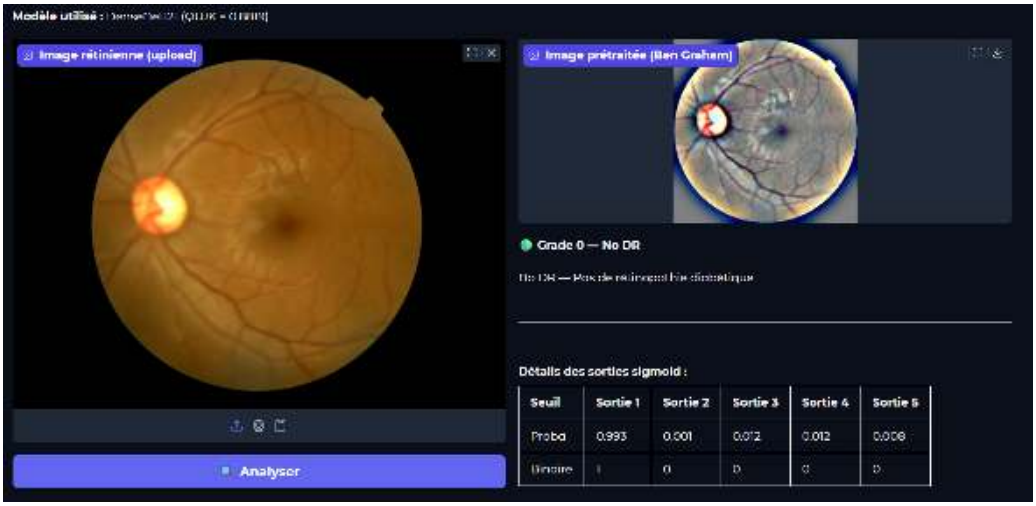


FIGURE 4.6 – Interface Gradio – Prédiction d'un cas **No DR** (Grade 0). Le modèle identifie correctement l'absence de rétinopathie avec des probabilités sigmoid très basses.

Cas 2 : Grade 1 – Mild (Rétinopathie légère)

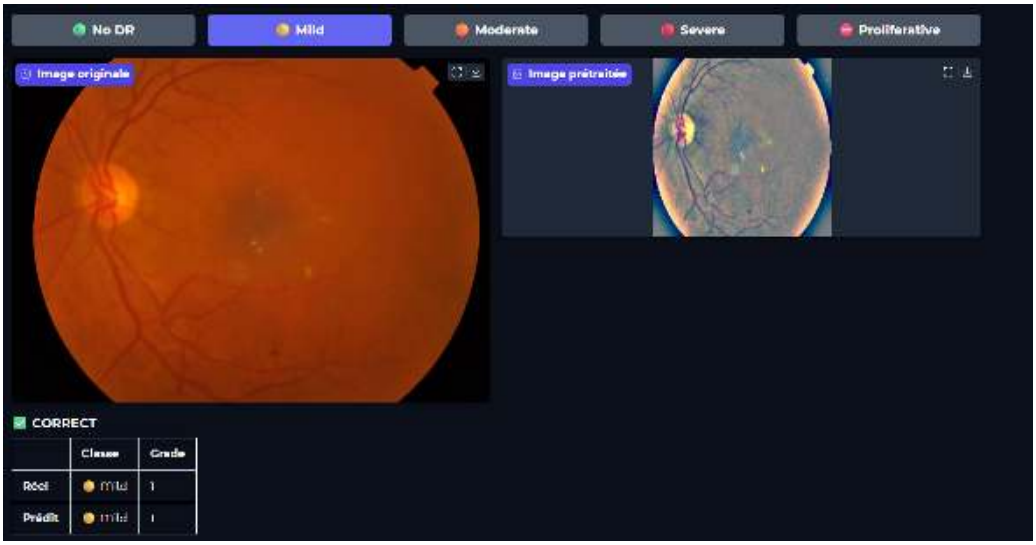


FIGURE 4.7 – Interface Gradio – Prédiction d'un cas **Mild** (Grade 1). Le modèle détecte les premiers signes de rétinopathie.

Cas 3 : Grade 2 – Moderate (Rétinopathie modérée)

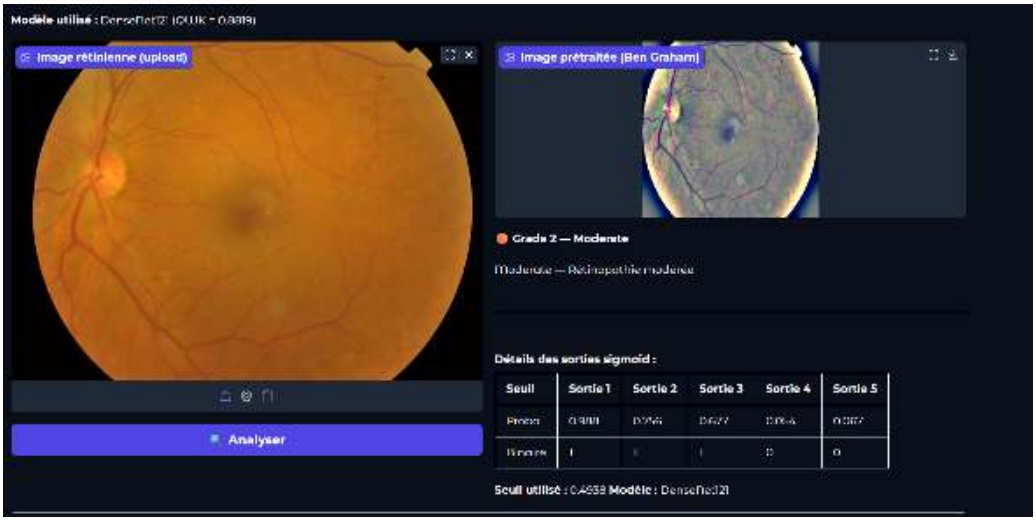
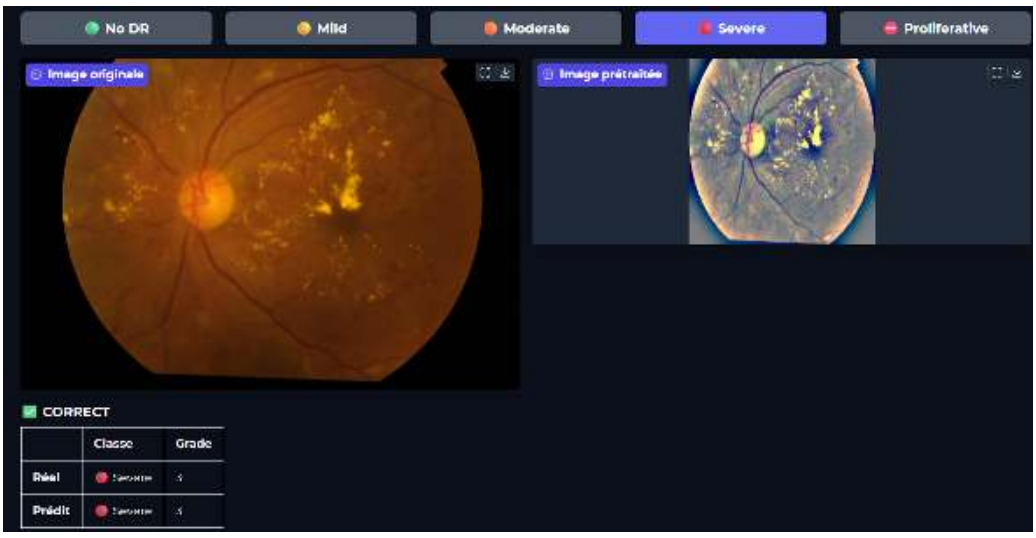


FIGURE 4.8 – Interface Gradio – Prédiction d'un cas **Moderate** (Grade 2). Les lésions sont plus prononcées.

Cas 4 : Grade 3 – Severe (Rétinopathie sévère)



Cas 5 : Grade 4 – Proliferative (Rétinopathie proliférative)

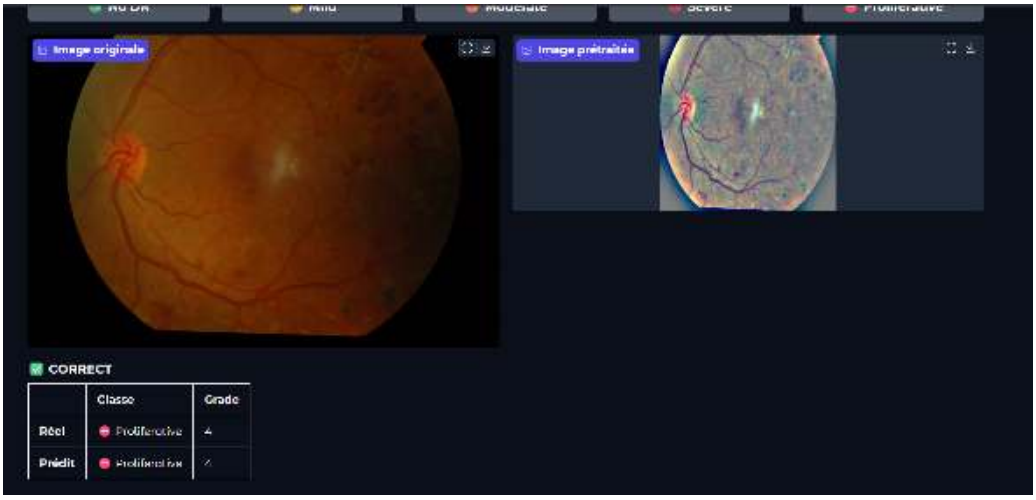


FIGURE 4.9 – Interface Gradio – Prédiction d'un cas **Proliferative** (Grade 4). Toutes les sorties sigmoid sont activées, confirmant le stade le plus sévère.

Conclusion et Perspectives

Synthèse des contributions

Ce projet a démontré l'efficacité de l'apprentissage profond pour la détection automatisée de la rétinopathie diabétique à partir d'images de fond d'œil, en exploitant une approche novatrice d'encodage ordinal multilabel. Les contributions principales de ce travail sont les suivantes.

Premièrement, la **validation de l'encodage ordinal multilabel** comme approche supérieure à la classification multiclasse standard pour les maladies progressives. En modélisant chaque sortie sigmoid comme un problème binaire indépendant avec un encodage cumulatif, le modèle apprend implicitement la structure ordinale de la rétinopathie diabétique.

Deuxièmement, la **comparaison rigoureuse de quatre architectures CNN** dans un cadre expérimental unifié a permis d'établir que DenseNet121, avec seulement 7M de paramètres, surpasse des architectures plus complexes (ResNet50 avec 25M, InceptionV3 avec 23M) sur ce dataset médical de taille modeste.

Troisièmement, l'**optimisation post-entraînement des seuils de décision** par la méthode de Nelder-Mead a permis d'améliorer les performances de chaque modèle individuel.

Quatrièmement, le **Test-Time Augmentation (TTA)** avec 8 transformations géométriques a amélioré le QWK de chaque modèle, avec un gain notable de +0,0359 pour EfficientNetB3 et +0,0111 pour DenseNet121, démontrant l'intérêt du moyennage des prédictions pour réduire la variance.

Cinquièmement, l'**ensemble optimisé des quatre modèles** a atteint le meilleur QWK global de **0,8964** (gain de +0,0163 vs baseline), confirmant que la combinaison d'architectures complémentaires avec optimisation conjointe des poids et du seuil surpasse tout modèle individuel.

Limitations

Plusieurs limitations doivent être reconnues :

- Le **déséquilibre sévère des classes** (ratio 9,4 :1) impacte significativement les performances sur les classes Severe et Mild, avec des F1-scores inférieurs à 0,55 même pour l'ensemble optimisé.
- La **taille limitée du dataset** (3 662 images) contraint la capacité des modèles les plus profonds et limite la généralisation.
- L'**absence de validation externe** sur un dataset indépendant (cross-site) rend incertaine la robustesse clinique.
- Aucune **analyse d'interprétabilité** (Grad-CAM, saliency maps) n'a été réalisée pour identifier les régions rétiniennes déterminantes dans les prédictions.

Perspectives futures

— **Méthodes d'interprétabilité :** Implémenter Grad-CAM et les cartes de saillance pour identifier les lésions rétiniennes sur lesquelles les modèles fondent leurs décisions, condition indispensable à l'adoption clinique.
— **Traitement du déséquilibre :** Explorer les techniques de focal loss, oversampling (SMOTE adapté aux images) et class-aware sampling pour améliorer les performances sur les classes sous-représentées.
— **Validation multi-site :** Évaluer les modèles sur des datasets indépendants (EyePACS, Messidor, IDRiD) pour quantifier la généralisabilité.
— **Déploiement clinique :** Intégrer le meilleur modèle dans une interface de téléophtalmologie, en s'appuyant sur le prototype Gradio développé.
— **Quantification et déploiement Edge :** Appliquer des techniques de quantification (INT8) et pruning pour permettre l'inférence sur des dispositifs à faibles ressources.

Bibliographie

[1] V. Gulshan, L. Peng, M. Coram, *et al.*, "Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs," *JAMA*, vol. 316, no. 22, pp. 2402–2410, 2016.

[2] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.

[3] G. Litjens, T. Kooi, B. E. Bejnordi, *et al.*, "A survey on deep learning in medical image analysis," *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.

[4] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in *Proceedings of the IEEE CVPR*, 2017, pp. 4700–4708.

[5] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE CVPR*, 2016, pp. 770–778.

[6] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proceedings of the IEEE CVPR*, 2016, pp. 2818–2826.

[7] M. Tan and Q. Le, "EfficientNet : Rethinking model scaling for convolutional neural networks," in *Proceedings of ICML*, 2019, pp. 6105–6114.

[8] Asia Pacific Tele-Ophthalmology Society, "APTOS 2019 Blindness Detection," Kaggle Competition, 2019. [Online]. Available : `https://www.kaggle.com/c/aptos2019-blindness-detection`

[9] B. Graham, "Kaggle Diabetic Retinopathy Detection Competition Report," 2015. [Online]. Available : `https://arxiv.org/abs/1502.02439`

[10] J. Cohen, "Weighted kappa : nominal scale agreement provision for scaled disagreement or partial credit," *Psychological Bulletin*, vol. 70, no. 4, pp. 213–220, 1968.